EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS

クラウド入門(最終回) - クラウド上でのMPI利用例 -

2012年4月28日 トップエスイー 国立情報学研究所 粂野文洋



本授業の位置づけ

- クラウドコンピューティング入門
- Web 三層モデル(1)-(3)
- \blacksquare Map-Reduce(1)-(2)
- MPIの利用例(今回)



本授業の内容

- MPIとは
- クラウド上でのMPI実行環境の構築実習
- MPIのサンプルプログラム実習
- モデル検査ツールDiVinE
- DiVinE Cluster(クラウド)の実習
- ■まとめ

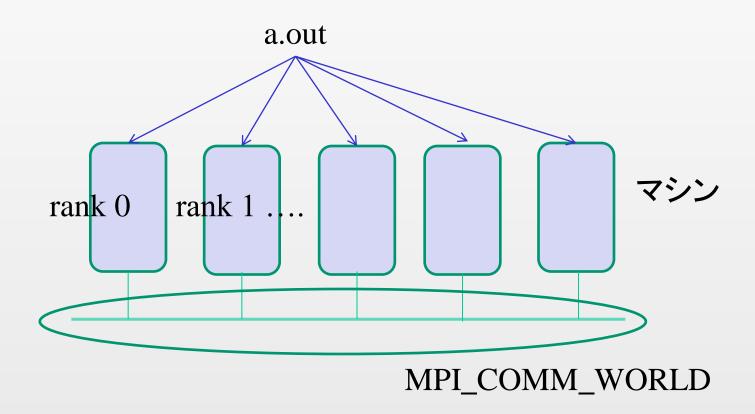


MPI

- MPI (Message Passing Interface)
 - ■分散メモリ型並列計算機上で並列プログラミング を行うためのAPI 仕様
 - ■代表的な実装: Open MPI、MPICH2
 - ■各マシン上で同一のプログラムを並列実行させ、 プロセス番号で分岐して処理を進めるスタイル
 - ■各プロセスは、メッセージを交換し合うことにより 協調して処理を進める



MPIによる並列計算





MPIが提供する機能

- ■基本機能
 - MPI_Init(&argc, &argv)
 - MPI_Comm_rank(MPI_COMM_WORLD, &my_rank)
 - MPI_Comm_size(MPI_COMM_WORLD, &p)
 - MPI_Finalize()
- ■一対一通信(同期型)
 - MPI_Send(buffer, count, datatype, destination, tag, communicator,ierr)
 - MPI_Recv(buffer, count, datatype, source, tag, communicator, status,ierr)

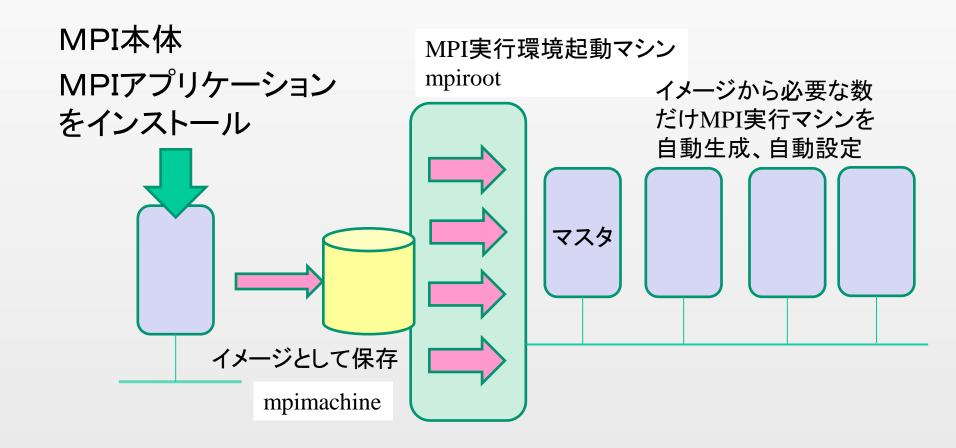


MPIが提供する機能

- ■集団通信(一部)
 - MPI_Bcast(message, count, datatype, root, comm,ierr)
 - MPI_Garher(sendbuf, sCount, sType, recvbuf, rCount, rType, root, comm,ierr)
 - MPI_Reduce(sendbuff,recvbuff,number_of_data,data_typ e,operation,dest,communicator,ierr)
- ■時間計測
 - MPI_Barrier(communicator,ierr)
 - MPI_Wtime()



クラウド上でのMPI実行環境構築



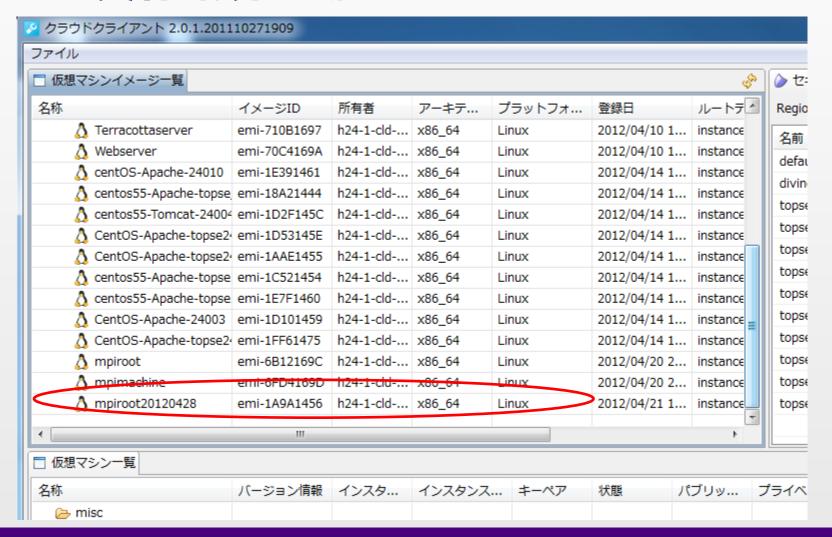
9 CHIERS EDUCATION OF THE PROPERTY OF THE PROP

Edubaseクラウド上のMPI実行環境構築(実習)

- 1. MPI実行環境起動マシンの立ち上げ
- 2. 環境設定
- 3. MPI実行マシンの生成
- 4. マスターマシンへのログイン
- 5. 実行ユーザへのログイン

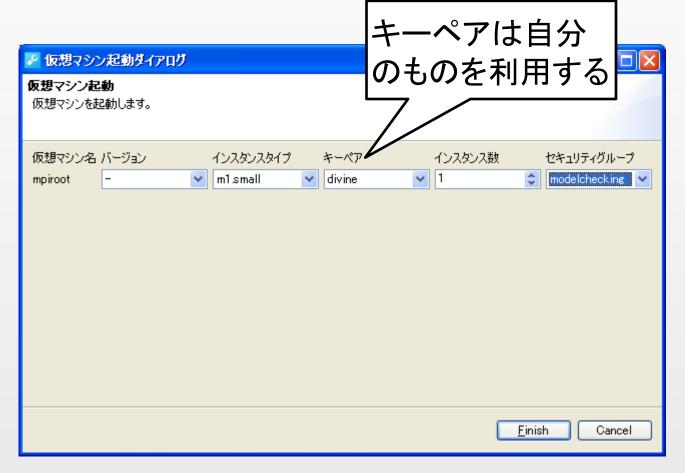


MPI実行環境起動マシンの立ち上げ



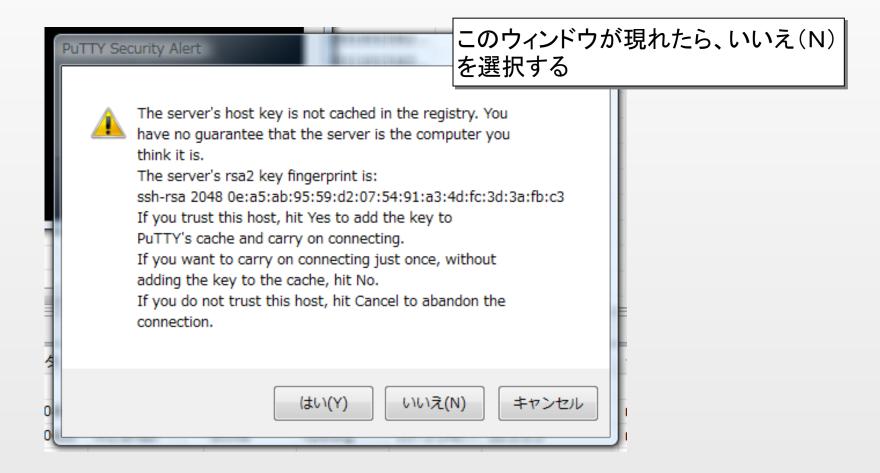
EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS

MPI実行環境起動マシンの各属性



2 CHIEERS EDUCATION OF THE NGINEERS OF THE NGI

SSHでログイン時の注意





MPI実行マシンの生成

- MPI実行環境起動マシン(mpiroot****)にログイ
- setupディレクトリに移動し、自分の環境に応じて env.shを編集、保存
- ■編集にはviを利用
- viの使い方(たとえば以下)

- 以下のコマンドを実行し、MPI実行マシンの生成 を行う
- ./Setup.sh -f ./env.sh



env.shの編集(1)

```
    root@localhost: ~/setup

#例:CLC=172.30.75.1
CËČ IP=vclc0006.ecloud.nii.ac.jp
#CLŌ IP=AWS
|######
#2.ミニクラウド認証情報
   <u> 仮想計算機システム上のミニクラウドに接続するために必要な認証情報です。</u>
クラウドクライアントの情報を参考に記載して下さい
#Access Key ID
|#例:ACCESS | KEY='p3Ar1C2uRBwa2FBXnCw₩Ky3Cw'
ACCESS_KEY='Go76gzMWRZYsIg5dSt0VA'
#Sercret Access Key
#例:SECRET_KEY='VrTHSnlBs46DwF9RAAM8KrvY90aPf1lsXflyLA'
SECRET_KEY='zmLaK3Rlut9ZM3Xn8yU1QZ1hKz6Os6AxGP0PQ'
####
#3.AWS認証情報
  AWS上で起動する際に必要な認証情報です。
#PRIVATE_KEY(PRIVATE_KEYのファイルパスを記入して下さい)
<mark>#</mark>例:PRIVATE_KEY=/root/ec2/pk-G5CZ35MWRQZ.pem
```



env.shの編集(2)

```
_ 0

    root@localhost: ~/setup

 ######
 #4.仮想マシン設定情報
#Image_ID
 IMAGĒ ĪD=emi-6FD4169D
 #keypair
 KEYPAIR=divine
#RSA花瓷鍵
#RSASEC=/root/.ssh/id_rsa-pub
#RSASEC=/root/.ssh/test.ppk
#RSASEC=/root/.ssh/divine.ppk
RSASEC=/root/.ssh/id_rsa
#仮想マシン台数
#NUM_VM=64
 NUM_∀M=4
 # The instance type:
#<mark>I</mark>NSTANCE_TYPE="m1.small"
```

6 CHEERS EDUCATION OF THE NGINEERS OF THARE OF THARE OF THARE OF THAT OF THE NGINEERS OF THE N

env.shの編集(3)

```
X

    root@localhost: ~/setup

#仮想マシン台数
#NUM_VM=64
NUM ⊽M=4
  The instance type:
#INSTANCE_TYPE= ml.small"
#INSTANCE_TYPE="ml.large"
#INSTANCE_TYPE="m1.xlarge"
INSTANCE_TYPE="c1.medium"
#INSTANCE_TYPE="c1.xlarge"
#Security Group
#何も指定しなければデフォルトのグループになります。
SECGROUP=divine
#####
  .仮想マシン停止情報
   停止する仮想マシンの情報を記載して下さい。
#MASTER仮想マシンのIP
#MASTERIP=157.1.145.135
```

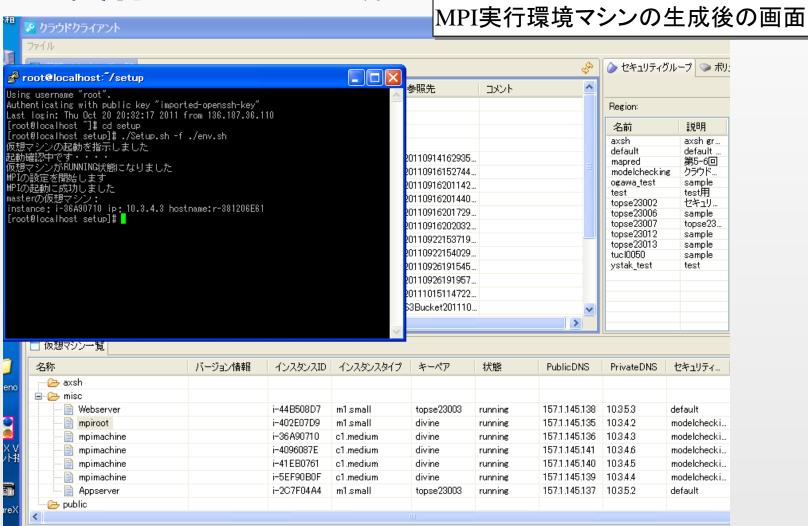


MPI実行マシンの生成



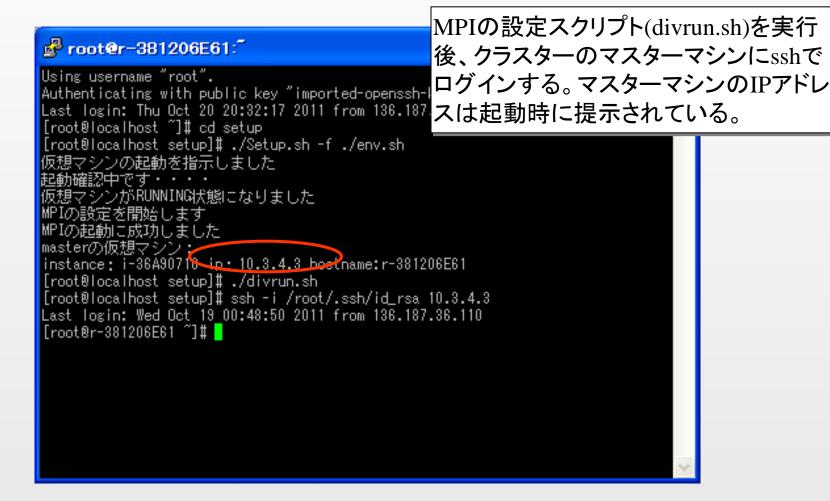


MPI実行マシンの生成





マスターマシンへのログイン





実行ユーザへのログイン

クラスターのマスターマシンにログイン 後、DiVinEユーザとなる。これでMPIア 🧬 divine@r−381206E61: ੌ プリケーション実行の準備は完了。 Using username "root". Authenticating with public key "imported-openssh-, Last login: Thu Oct 20 20:32:17 2011 from 136.187.36.110 [root@localhost ~]# cd setup [root@localhost setup]# ./Setup.sh -f ./env.sh マシンの起動を指示しました がRUNNING状態になりました instance: i-36A90710 ip: 10.3.4.3 hostname:r-381206E61 [root@localhost_setup]# ./divrun.sh [root@localhost_setup]# ssh -i /root/.ssh/id_rsa 10.3.4.3 Last login: Wed Oct 19 00:48:50 2011 from 136.187.36.110 [root@r-381206E61 ~]# su - divine [divine@r-381206E61 ~]\$

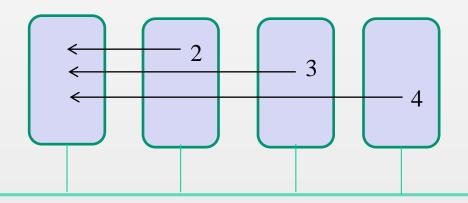
EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS

MPIのサンプルプログラム

sample1.c

size=4

rank=1 rank=2 rank=3 rank=0

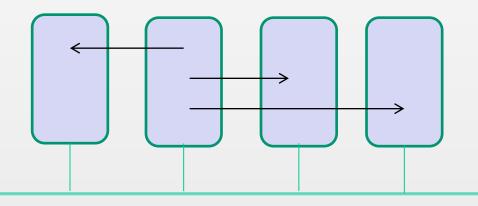


MPIのサンプルプログラム

sample2.c

size=4

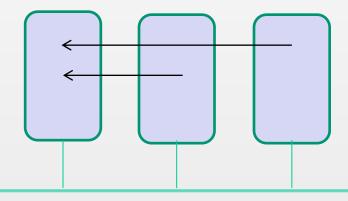
rank=1 rank=2 rank=3 rank=0



MPIのサンプルプログラム

sample3.c

size=3

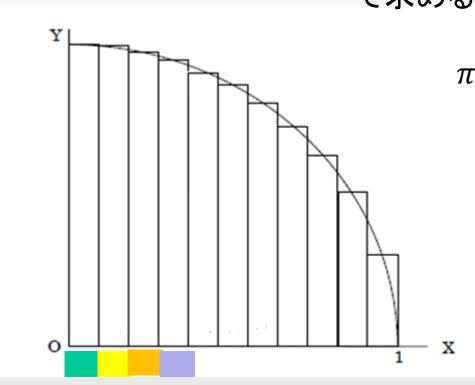


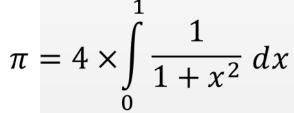
EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS

MPIのサンプルプログラム

sample4.c

円周率を区分求積法の積分計算 で求める





- rank 0
- rank 1
- rank 2
- rank 3



MPIサンプルプログラムの実行 (実習)

- シェルからの入力コマンド mpirun -n ノード数 sample/sample{1,2,3,4}
- ■実行と出力結果の確認
 - sample 1
 - sample2
 - sample3
- ■時間計測
 - sample4(1台、2台、4台)
 - ■間隔が粗い場合、細かい場合で台数効果を比較 してみる



sample4の実行例

```
    divine@r-41B308561:∼

/root/setup
root@localhost setup]# vi ./env.sh
root@localhost setup]# pwd
/root/setup
 root@localhost setup]# ./Setup.sh -f ./env.sh
 仮想マシンの起動を指示しました
      シンがRUNNING状態になりました
|instance:i-4F320886 ip:10.3.4.130 hostname:r-41B308561
[root@localhost setup]# ssh -i /root/.ssh/id_rsa 10.3.4.130
Last login: Wed Oct 19 00:48:50 2011 from 136.187.36.110
[root@r-41B308561 ~]# su - divine
divine@r-41B308561
      error mpd.hosts sample test
[divine@r-41B308561 ~]$ mpirun -n 4 sample/sample4
Enter the number of intervals
1000
ln=1000
 pi is approximately: 3.1415927369231267 Error is:0.0000000833333336
 execution time = 0.0014 [sec.]
[divine@r-41B308561
```

EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS

モデル検査ツールDiVinE



モデル検査技術

■ システムをモデル化した状態遷移システムの状態空間を 網羅的に探索することにより、与えられた性質が正しいか どうかを判定する検証方法

■ 特長

- ■完全な自動化が可能
- ■必要な専門知識が比較的少ない
- ■部分的な仕様でも検証可能、様々な仕様記述
- ■反例の提示
- ■問題点
 - ■探索空間のサイズ(state explosion problem)
 - ■取り扱える状態数:104から105(初期)、10120(現在)

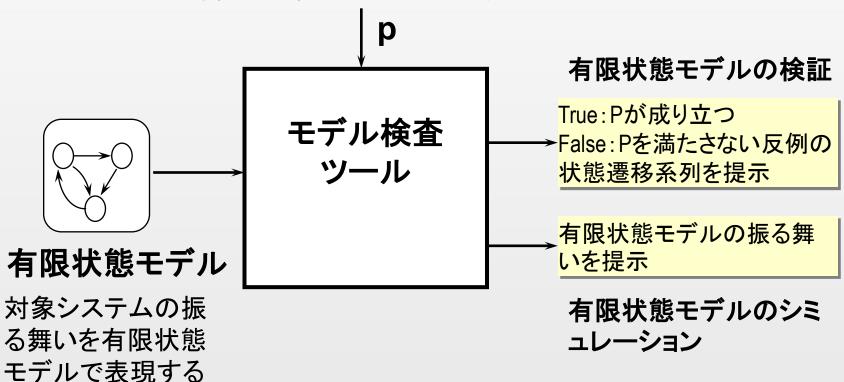
EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS



モデル検査ツール

対象システムが満たすべき性質

時相論理の論理式等で記述する



SO GIVERS EDUCATION DE PROPERTIES DE THARE DE NGINEERS DO NOT HOUNTED

相互排除プログラム

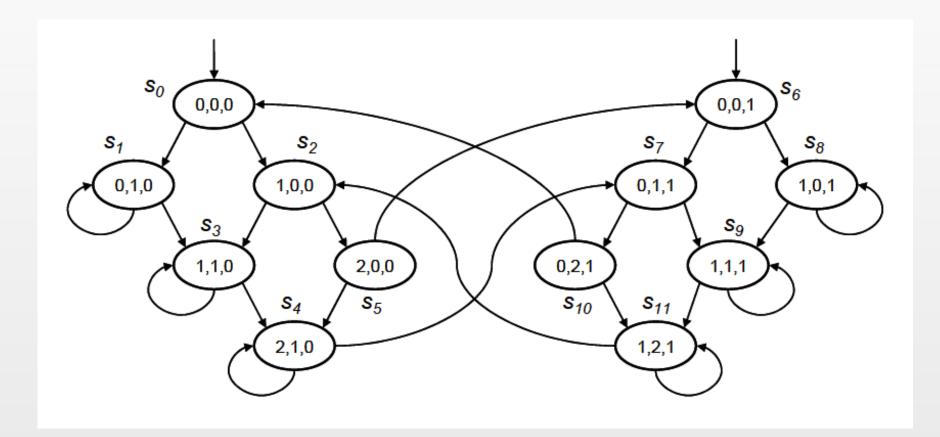
```
P0 0: while True {
    1: wait(t == 0);
    2: t := 1; }

P1 0: while True {
    1: wait(t == 1);
    2: t := 0; }
```

- プログラムPi のプログラムカウンターpci(i = 0, 1)
- クリティカル・セクションpci = 2 (i = 0, 1)
- ●共有変数t(初期値は不定だが、ここでは0か1とする)
- ◆ 状態 各プログラムのプログラムカウンターと共有変数の対(pc0, pc1, t)

HANNERS EDUCATION OF THE PROPERTY OF THE PROPE

状態遷移図



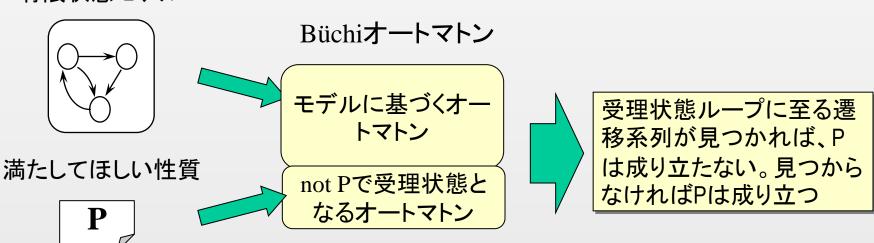
EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS



モデル検査の実装

オートマトン理論に基づくモデル検査 有限状態モデルと性質をBüchiオートマトンに変換 Büchiオートマトンの合成および空検査

有限状態モデル





分散モデル検査とは

- 課題:状態爆発による検証能力の限界
- 解決アプローチ
 - 抽象化
 - 実装アルゴリズムの改良
 - 分散•並列化



DiVinE Project

- チェコ Masaryk University ParaDise Laboratory で開発
- DIVINE
 - DIVINE Cluster
 - DIVINE Multi-Core
 - PROB-DIVINE
 - DivSPIN、NIPS
- DIVINE CUDA



DiVinE で採用しているモデル検査実装

- 並列処理向けの様々なモデル検査実装を開発
 - Algorithm based on dependency structure
 - Algorithm based on negative cycles
 - Property Driven Nested DFS
 - SCC-based algorithm (OWCTY)
 - Algorithm based on back-level edges
 - Algorithm based on maximal accepting predecessors (MAP)



スケーラビリティ(DiVinE Cluster)

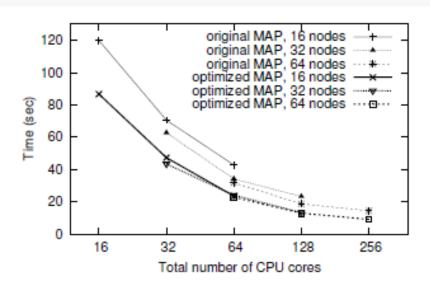


Figure 3. Optimization effects for MAP

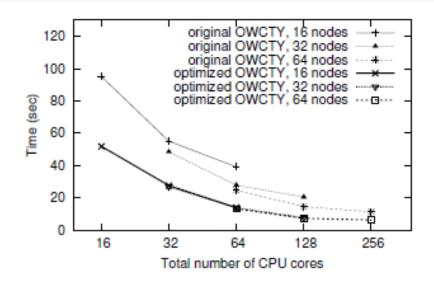


Figure 4. Optimizations effects for OWCTY



BEEM: BEnchmarks for Explicit Model checkers

- DiVinE Clusterの性能ベンチマーク
- http://anna.fi.muni.cz/models/index.html
- 非常に多くの問題がとりあげられている



- 例題:人間と自動販売機
 - ■人間は働き、金を稼ぐ
 - ■稼いだ金を持って自動販売機の場所にいく
 - ■自動販売機に金を入れる
 - ■飲み物を選び、出てくるのを待つ
 - ■選んだ物が出てきたら幸せな状態になる
 - ■違う物が出てきたら悲しい状態になる
 - ■幸せな状態になったら、再び働く状態に戻る



- 例題:人間と自動販売機(続き)
 - ■自動販売機の制御部は金が入るのを待っている
 - ■金が入り、飲み物が選ばれると機械に飲み物を 用意するように要求する
 - ■機械は制御部からの要求を待っている
 - ■要求をもらうと要求された飲み物を用意する。
 - ■飲み物が取り出されると、もとの待ち状態に戻る



■ 記述例:人間

```
process man {
byte what, want, money;
state working, give_money, wait, got, happy, sad;
init working;
trans
working ->give_money { effect money = 1; },
give_money->give_money { guard money>0; sync in!;
effect money = 0; },
give_money->wait { sync req!0; effect want = 0; },
give_money->wait { sync req!1; effect want = 1; },
wait ->got { sync take?what;},
got ->happy { guard what == want; },
got ->sad { guard what != want; },
happy ->working { };
```



■ 記述例:自動販売機(制御部)

```
process control_unit {
  byte money, choice;
  state ready, request;
  init ready;
  trans
  ready ->ready { sync in?; effect money = 1; },
  ready ->request { sync req?choice; },
  request->ready { guard choice==0 and money;
  sync make!0; effect money=0;},
  request->ready { guard choice==1 and money;
  sync make!1; effect money=0;},
  request->ready { guard not money; };
}
```



■ 記述例:自動販売機(機械)

```
process mechanic_parts {
byte product;
state ready, produce,
error st;
init ready;
trans
ready -> produce
{ sync make?product; },
produce -> error_st
{ sync make?product; },
error_st -> error_st
{ sync make?product; },
produce -> ready
{ sync take!product; };
```



□ 構文 **Processes** process プロセス名 Variables { プロセスのコード } グローバル変数とローカル変数がある。以下は変数定義の例である。 byte A[9]; int i,j; Constants 以下は定数定義の例である。 const byte k = 3; なお、配列定義のパラメータに利用できない。以下はエラーである。 byte field[k];



□ 構文

Process states

state変数でプロセスの状態を表現する。この定義の後、どの変数がプロセスの初期状態かを指定する必要がある。

またアトミックアクションを定義するためのstate変数を定義することもできる。

Transitions

プロセスの状態遷移はstate変数を使い、以下のように定義する。 変数名 -> 変数名 { 遷移が起きる条件(ガード部分) }



□ 構文

Expressions

ガード部や同期変数で使える算術式の構成要素は以下のとおりである。

- ·定数(数, true, false)
- ・かっこ、カンマ
- •変数識別子
- ・以下の論理演算子

-, \sim , not, imply, or, and, |, $^$, &, ==, !=, <, <=, >, >=, <<, >>, -, +, /, *, %

・プロセスの状態に関する問い合わせ たとえばプロセスSenderがready状態であれば、問い合わせ Sender.ready は1に等しい。それ以外の状態なら0に等しい。



□ 構文

Channels

プロセス間の通信チャネルはグローバル変数で定義する。定義例を以下に示す。 channel send, receive, toK, fromK, toL, fromL; // 型なしのチャネル channel {byte} b_send[0], b_receive[0]; // バッファなしのチャネル channel {byte,int} bi_send[0], bi_receive[0]; //2つの値を同時に送信 するチャネル channel {byte,int} buf_bi_send[4], buf_bi_receive[1]; //型つき、 バッファ付きチャネル

Type of a system

同期的動作する並行システムか非同期並行に動作するシステムかを指定できる。全体定義の一番最後に記述する。



□ 構文

Assertions

```
プロセスが指定の場所でとるべき状態の条件(State変数に関する条件式)
をAssertionで定義できる。以下は定義の例である。
process My process
  byte hello = 1;
  state one, two, three;
  init one;
  assert one: hello >= 1,
        two: hello < 1,
        one: hello < 6;
  trans
```



別の記述例(哲学者の食事の問題、4人の場合)

```
byte fork[4];
process phil_0 {
state think, one, eat, finish;
init think;
trans
think -> one \{\text{guard fork}[0] == 0; \text{ effect fork}[0] = 1; \}
one -> eat \{guard fork[1] == 0; effect fork[1] = 1;\},
eat -> finish \{effect fork[0] = 0; \},
finish -> think {effect fork[1] = 0; };
process phil_1 {
state think, one, eat, finish;
init think;
trans
think -> one \{\text{guard fork}[1] == 0; \text{ effect fork}[1] = 1; \}
one -> eat \{\text{quard fork}[2] == 0; \text{ effect fork}[2] = 1;\}
eat -> finish {effect fork[1] = 0; },
finish -> think {effect fork[2] = 0; };
```



別の記述例(続き)

```
process phil_2 {
state think, one, eat, finish;
init think;
trans
think -> one \{\text{quard fork}[2] == 0; \text{ effect fork}[2] = 1; \}
one -> eat \{guard fork[3] == 0; effect fork[3] = 1;\},
eat -> finish \{effect fork[2] = 0; \},
finish -> think {effect fork[3] = 0; };
process phil_3 {
state think, one, eat, finish;
init think;
trans
think -> one \{\text{quard fork}[3] == 0; \text{ effect fork}[3] = 1; \}
one -> eat \{guard fork[0] == 0; effect fork[0] = 1;\},
eat -> finish \{effect fork[3] = 0; \},
finish -> think {effect fork[0] = 0; };
system async;
```



性質の記述

- 検証したい性質をDVE言語で記述(process LTLproperty)
- ■LTLの検証式からDVE記述の変換ツールも一応 サポート
- VDE言語によるシステム記述と性質の記述をひとつのファイルにする。



性質の記述例

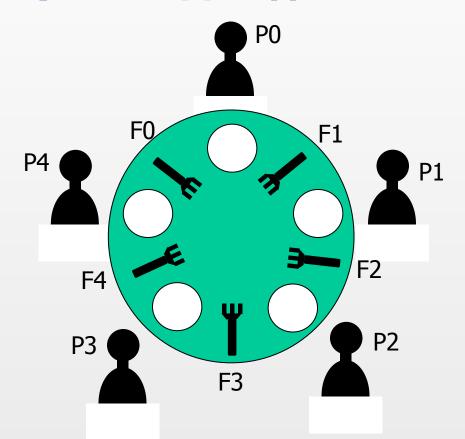
- 人間と自動販売機の例
- ■検証したい性質:人間は決して悲しい状態にならない。
 - process manにおいて、man.sadは真にならない。
 - ■man.sadが真になると受理状態ループになるオートマトンをDVE記述に追加する。
- 具体例:ファイル man_and_machine.prop.dve



Edubaseクラウドを使ったDiVinE Cluster実習

- 1. 例題説明
- 2. DiVinE Clusterによる並列実行
- 3. 台数効果の検証

例題:食事をする哲学者の問題



食事を食べ続けられる各哲学者プロセスを開発しなさい



哲学者が行える動作

- フォークをひとつずつ握ることができる
- 握っているフォークをひとつずつ離すことができる
- 二つのフォークを握ることで食事を食べることができる
- 隣の哲学者がフォークを握っていないときにのみ フォークを握ることができる。



DiVinE Clusterを使った演習

- 哲学者の食事の問題
 - phils.1.dve:哲学者は4名。動作は同じ
 - phils.5.dve:哲学者は12名。動作は同じ
 - phils.6.dve:哲学者は15名。動作は同じ
- 検証したい性質
 - 哲学者0は食事にありつけることが永続される (phils.*.prop1.dve)
 - 2. 哲学者0は最初のフォークを掴んだら、いつかは食事にあり つける(phils.*.prop2.dve)
 - 3. 哲学者の誰でも食事にあるつけることが永続される (phils.*.prop3.dve)



問題ファイル

```
X

    divine@r-41B308561:∼

[divine@r-41B308561 ~]$ Is data/phils/generated files/
                   phils.2.stat.xml
                                       phils.4.prop3.dve
                                                          phils.7.dve
lphils.1.dve
phils.1.pm
                   phils.3.dve
                                       phils.5.dve
                                                          phils.7.pm
phils.1.prop1.dve
                   phils.3.pm
                                       phils.5.pm
                                                          phils.7.prop1.dve
                   phils.3.prop1.dve
                                       phils.5.prop1.dve
                                                          phils.7.prop2.dve
phils.1.prop2.dve
phils.1.prop3.dve
                   phils.3.prop2.dve
                                       phils.5.prop2.dve
                                                          phils.7.prop3.dve
phils.1.stat.xml
                   phils.3.prop3.dve
                                       phils.5.prop3.dve
                                                          phils.8.dve
                                                          phils.8.pm
phils.2.dve
                   phils.3.stat.xml
                                       phils.6.dve
                   phils.4.dve
                                       phils.6.pm
phils.2.pm
                                                          phils.8.prop1.dve
                   phils.4.pm
phils.2.prop1.dve
                                       phils.6.prop1.dve
                                                          phils.8.prop2.dve
                   phils.4.prop1.dve
                                       phils.6.prop2.dve
                                                          phils.8.prop3.dve
phils.2.prop2.dve
phils.2.prop3.dve
                   phils.4.prop2.dve
                                       phils.6.prop3.dve
                                                          results.xml
[divine@r-41B308561 ~]$
```

EDUCATION PROGRAM FOR TOP SOFTWARE

DiVinEの並列実行はmpirunを使って実行する。以下の画面は4ノードを利用している例である。



```
divine@r-41B308561 ~]$ mpirun -n 4 divine.owcty data/phils/generated_files/phil]
 5.prop1.dve
       --- Accepting cycle ---
                       1062879
States:
transitions:
                       11849122
iterations:
size of a state:
                       80
size of appendix:
                       8887059
cross transitions:
                       548.445 MB
all memory:
                       18.1813 s
time:
012: local states: 3: local states: 265522265181: local states:
65706
 local states: 266470
012: local memory:     : local memory:       3136.938: local memory:       137.09
4137.156
  local memory:
                    137.258
```

EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS



以下の画面は2ノードを利用している例である。

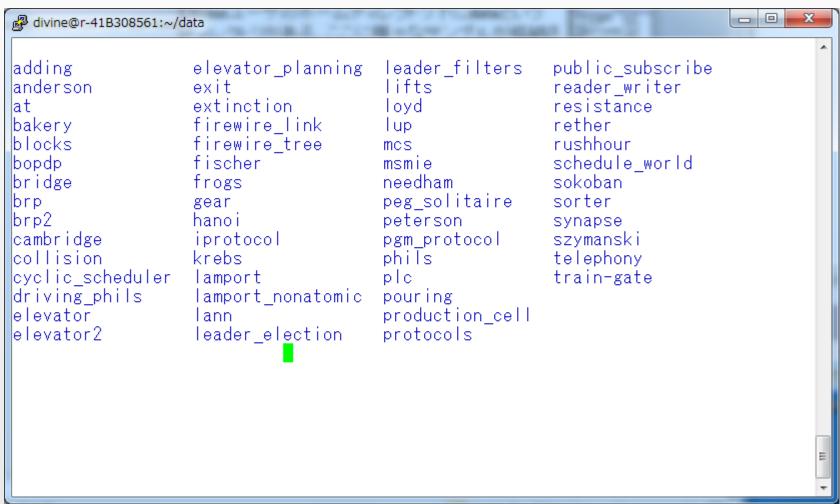
```
- -
divine@r-41B308561:~
[divine@r-41B308561 ~]$ mpirun -n 2 divine.owcty data/phils/generated_files/phit
 .5.prop1.dve
           Accepting cycle -
                          1062879
States:
transitions:
                          11849122
iterations:
size of a state:
size of appendix:
cross transitions:
                          5924046
                          359.406 MB
all memory:
                          29.2902 s
time:
01: local states:
                         530887
  local states:
                      531992
  : local memory: 179.559
local memory: 179.848
[divine@r-41B308561 ~]$ 📙
```

Top SE

EDUCATION PROGRAM FOR TOP SOFTWAP

Divineユーザのホームディレクトリ下にdataという ディレクトリがある。ここに様々なサンプルが格納さ れている。







DiVinE Clusterを使った演習

- 問題ファイルのパス
 - data/phils/generated_files/phils.*.prop*.dve
- クラウド上における分散モデル検査の台数効果は?
 - ノードが1つの場合
 - ノードが2つの場合
 - ノードが4つの場合

EDUCATION PROGRAM FOR TOP SOFTWARE ENGINEERS



シャットダウンの方法

```
ログアウトし、MPI実行環境起動マシン
🗗 root@localhost: 🖊 setup
                                           に戻る。
Using username "root".
                                          MPI実行環境起動マシンのsetupディク
Authenticating with public key "imported-opens
Last login: Thu Oct 20 19:47:11 2011 from 136.レトリからシャットダウン用のスクリプト
[root@localhost ~]#
                                          を実行する
[root@localhost
[root@localhost ~]# cd setup/
[root@localhost_setup]# Is
Setup.sh Set<del>uphelp Shutdown.sh Shutdownhe</del>lp divrun.sh <del>env.sh</del>
[root@localbost_setup]# ./Shutdown.sh -f ./env.sh -m 10.3.4.3
               1たマシンより、停止させる恢想マンフの一覧を取得します
  止した仮想マシン:
 0.3.4.4
 0.3.4.5
10.3.4.6
[root@localhost_setup]#
```

DivineユーザおよびMPI実行マシンを



本講義のまとめ

- クラウドによるMPIの利用事例
- MPI実行環境の構築
- MPIのサンプルプログラム、アプリケーションの 実習
- クラウドによる並列計算の効果